INGENIERÍA DEL DATO

Recolección, tratamiento y análisis exploratorio del dataset de imágenes de packaging de productos de consumo

TFG — Análisis del impacto del color del packaging en las emociones del consumidor

Universidad Francisco de Vitoria · Curso 2024-2025

10.480	3	67	7
Productos totales	Fuentes de datos	Categorías	Variables de color

1. Objetivo y justificación de la recolección de datos

El presente TFG tiene como objetivo analizar el impacto del color del packaging de productos de consumo en las emociones del consumidor, con el fin de extraer conclusiones accionables para el marketing y el diseño de producto. Para ello, el primer reto metodológico consiste en construir un **dataset de imágenes de packaging con suficiente volumen, variedad de categorías y calidad cromática** para que las variables de color extraídas sean representativas y el modelo posterior sea robusto.

La principal alternativa considerada inicialmente fue el uso de datasets académicos preexistentes, en particular **Google Open Images Dataset v7**, que contiene más de 9 millones de imágenes etiquetadas con 600 clases de objetos. Sin embargo, este dataset presenta una limitación crítica para el objetivo del estudio: las imágenes son fotografías naturalistas tomadas en contextos reales, donde el producto puede aparecer en segundo plano, parcialmente ocluido, bajo condiciones de iluminación variables, o rodeado de otros elementos visuales que contaminan la medición del color del packaging. En consecuencia, se optó por una estrategia de **recolección de imágenes de catálogo directamente desde fuentes de comercio electrónico**, donde las imágenes son fotografías de producto con fondo neutro, correctamente encuadradas y diseñadas específicamente para representar el color real del producto tal como lo percibe el consumidor en el punto de venta digital.

Esta decisión metodológica tiene tres ventajas directas para la calidad del análisis: primero, el color medido refleja la **intención de diseño de la marca** (el color que la empresa ha elegido deliberadamente para comunicar su propuesta de valor); segundo, las imágenes son homogéneas en cuanto a condiciones de captura, lo que reduce el ruido en la extracción de características cromáticas; y tercero, la estructura de categorías de los e-commerce proporciona una clasificación de producto directamente utilizable como variable de segmentación.

2. Fuentes de datos: selección y justificación

El dataset final combina tres fuentes complementarias que cubren categorías de producto diversas y cuya viabilidad técnica y legal fue verificada previamente al proceso de recolección.

2.1. Amazon Berkeley Objects (ABO)

La fuente principal del dataset es el **Amazon Berkeley Objects (ABO) Dataset**, desarrollado conjuntamente por Amazon y la Universidad de California Berkeley y presentado en la conferencia CVPR 2022 (Collins et al., 2022). Este dataset contiene 147.702 listings de productos de Amazon con 398.212 imágenes de catálogo en alta resolución, distribuidas en más de 90 categorías de producto que abarcan moda, hogar, cocina, tecnología, cosmética, juguetes y deportes.

La selección de ABO como fuente principal se justifica por cuatro razones: (1) las imágenes son fotografías profesionales de catálogo con fondo blanco o neutro, optimizadas para la percepción del color del producto; (2) cada producto incluye metadatos estructurados como *product_type*, marca, material y el campo *color_code* con el código HEX del color declarado por el fabricante, lo que permite validar la extracción cromática automática; (3) el dataset está publicado bajo licencia **CC BY-NC 4.0**, lo que autoriza expresamente su uso para investigación académica y lo hace perfectamente citable; y (4) los metadatos y las URLs de las imágenes están disponibles en archivos JSON comprimidos en servidores S3 de Amazon de acceso público, sin necesidad de scraping dinámico con navegador.

Del total disponible se extrajeron **7.777 productos** pertenecientes a las categorías de consumo más relevantes para el estudio, filtrando por *product_type* mediante una lista de 65 tipos de producto predefinidos.

2.2. Open Food Facts

La segunda fuente es **Open Food Facts**, una base de datos colaborativa y abierta de productos alimentarios y de higiene con más de 4 millones de productos indexados. Su API pública permite consultas filtradas por país, categoría y disponibilidad de imagen frontal, lo que facilita la extracción sistemática de productos del mercado español.

Esta fuente aporta al dataset la categoría de **alimentación y bebidas**, que tiene un interés especial para el análisis de color-emoción en marketing dado el peso que el color del packaging tiene en la decisión de compra en este sector (Labrecque & Milne, 2012). Open Food Facts está publicado bajo licencia **Open Database License (ODbL)**, que permite explícitamente su uso académico con la obligación de citar la fuente. Se extrajeron **2.622 productos** distribuidos en 30 categorías alimentarias.

2.3. Mahou San Miguel

La tercera fuente es la tienda online de **Mahou San Miguel**, el mayor grupo cervecero español, que incluye marcas como Mahou, San Miguel, Alhambra, Solán de Cabras y otras. Esta fuente se incluye como caso de estudio de **branding cromático en el sector de bebidas alcohólicas**, donde el color del packaging es especialmente relevante para la diferenciación de producto en el lineal. La verificación del fichero *robots.txt* del sitio confirmó que el acceso a las páginas de catálogo de producto estaba permitido para agentes automatizados. Se extrajeron **81 productos** de las marcas del grupo.

Fuente	Tipo de acceso	Licencia	Productos	Categorías principales

Amazon Berkeley Objects (ABO)	API pública S3 (descarga directa)	CC BY-NC 4.0	7.777	Moda, Hogar, Tecnología, Cosmética, Juguetes
Open Food Facts	API REST pública	ODbL (abierta)	2.622	Alimentación, Bebidas, Higiene
Mahou San Miguel	Web scraping (robots.txt verificado)	Uso académico (robots.txt)	81	Cervezas, Agua, Bebidas espirituosas
TOTAL			**10.480**	**67 categorías**

Tabla 1. Resumen de fuentes de datos utilizadas en el estudio.

3. Proceso de extracción de datos

3.1. Consideraciones legales y éticas

Antes de proceder a la extracción de datos de cualquier fuente web, se verificó el fichero ***robots.txt*** de cada sitio, que es el estándar técnico utilizado por los operadores de sitios web para indicar qué rutas pueden ser accedidas por agentes automatizados. Esta verificación es el paso previo imprescindible en cualquier proceso de web scraping académicamente responsable. En todos los casos, las rutas de catálogo de producto utilizadas estaban permitidas. Para las fuentes con API pública (ABO y Open Food Facts), no se plantea ninguna restricción de acceso dado que las propias organizaciones ponen los datos a disposición de investigadores de forma explícita.

Adicionalmente, todos los scripts implementados incorporan pausas de entre 1 y 3 segundos entre peticiones para no sobrecargar los servidores, siguiendo las buenas prácticas de scraping responsable.

3.2. Pipeline de extracción: arquitectura común

Los tres scrapers implementados comparten una arquitectura de tres fases secuenciales:

Fase 1 — Recolección de URLs y metadatos

Se navega por la estructura de categorías de cada fuente y se extraen los identificadores de producto, nombres, categorías y URLs de imagen. En el caso de ABO, esto se realiza deserializando los archivos de metadatos JSON comprimidos (.json.gz) descargados de S3. En Open Food Facts, se realizan llamadas paginadas a la API REST filtrando por country_tags=en:spain y por categoría. En Mahou San Miguel, se utiliza Selenium con Chrome en modo headless para renderizar el JavaScript dinámico de la página y extraer los productos de cada sección del catálogo.

Fase 2 — Descarga de imágenes

Para cada producto identificado se descarga la imagen frontal de packaging en resolución media-alta (512px o equivalente). Las imágenes se guardan localmente en formato JPEG con nomenclatura normalizada que incluye el identificador de la fuente, el índice numérico y el identificador del producto. Se implementa un sistema de caché que evita re-descargar imágenes ya procesadas en caso de interrupción y reanudación del proceso.

Fase 3 — Extracción de variables de color

Sobre cada imagen descargada se aplica el pipeline de análisis cromático descrito en la Sección 4. El resultado se añade como nuevas columnas al registro del producto y el conjunto completo se exporta a un archivo CSV codificado en UTF-8-sig para compatibilidad con caracteres especiales del español.

3.3. Combinación de fuentes y construcción del dataset final

Los tres CSV generados por los scrapers se combinaron en un único dataset mediante un script de unificación que: (1) selecciona únicamente las columnas comunes relevantes para el análisis (fuente, categoría, nombre, imagen_url y las 7 variables de color); (2) elimina filas con valores nulos en las variables de color; y (3) elimina duplicados identificados por URL de imagen para evitar que un mismo producto aparezca indexado en varias categorías. El resultado es un dataset de **10.480 productos únicos** con **11 columnas** y sin ningún valor nulo.

4. Extracción de variables de color

El análisis cromático de cada imagen se realiza mediante un pipeline automatizado implementado con las librerías Python *Pillow* (procesamiento de imagen) y *scikit-image* (conversión de espacios de color). Para cada imagen se calculan siete variables numéricas que caracterizan su color desde dos perspectivas complementarias.

4.1. Espacio de color RGB

Las tres primeras variables corresponden al **espacio de color RGB** (Red, Green, Blue), que es el sistema de representación nativo de las imágenes digitales. Para cada canal se calcula la media aritmética de los valores de todos los píxeles de la imagen, obteniéndose tres variables continuas en el rango [0, 255]: **mean_R** (componente roja), **mean_G** (componente verde) y **mean_B** (componente azul).

4.2. Espacio de color CIELAB

Las tres variables siguientes corresponden al **espacio de color CIELAB** (L*a*b*), desarrollado por la Comisión Internacional de Iluminación (CIE) y diseñado para ser **perceptualmente uniforme**: distancias iguales en el espacio L*a*b* corresponden a diferencias perceptuales iguales para el ojo humano. Esta propiedad lo hace especialmente adecuado para el análisis psicológico del color, siendo el espacio de referencia en los estudios más rigurosos de color y emoción, incluyendo los papers de Valdez & Mehrabian (1994) y Gilbert et al. (2016) citados en este TFG.

La variable **mean_L** mide la **luminosidad** en el rango [0, 100], donde 0 corresponde al negro absoluto y 100 al blanco perfecto. La variable **mean_a** mide la oposición **rojo-verde** en el rango [-128, +128], con valores positivos indicando tonos rojizos y negativos tonos verdosos. La variable **mean_b** mide la oposición **amarillo-azul** en el mismo rango, con valores positivos para tonos amarillentos y negativos para azulados. La conversión de RGB a CIELAB se realiza siguiendo el estándar CIE D65 (iluminante de luz diurna).

4.3. Contraste de luminosidad

La séptima variable, **contrast_L**, mide la **desviación típica de la luminosidad L* sobre todos los píxeles** de la imagen. Esta variable cuantifica la variabilidad interna del color de cada imagen: un valor alto indica que el packaging combina zonas muy luminosas y muy oscuras (alto contraste), mientras que un valor bajo indica que el color es uniforme. El contraste visual es una dimensión relevante en psicología del color porque está relacionado con la percepción de complejidad, dinamismo y activación emocional.

Variable	Espacio	Rango	Descripción
mean_R	RGB	[0, 255]	Media del canal rojo sobre todos los píxeles
mean_G	RGB	[0, 255]	Media del canal verde sobre todos los píxeles
mean_B	RGB	[0, 255]	Media del canal azul sobre todos los píxeles
mean_L	CIELAB	[0, 100]	Luminosidad media (0=negro, 100=blanco)
mean_a	CIELAB	[-128, +128]	Componente rojo(+)/verde(-) media

mean_b	CIELAB	[-128, +128]	Componente amarillo(+)/azul(-) media
contrast_L	CIELAB	[0, 100]	Desviación típica de L* (contraste interno)

Tabla 2. Variables de color extraídas de cada imagen de packaging.

5. Distribución del dataset

El dataset final contiene **10.480 productos únicos** distribuidos en **67 categorías** procedentes de **3 fuentes** de datos. A continuación se presentan los principales descriptores de su composición.

5.1. Distribución por fuente de datos

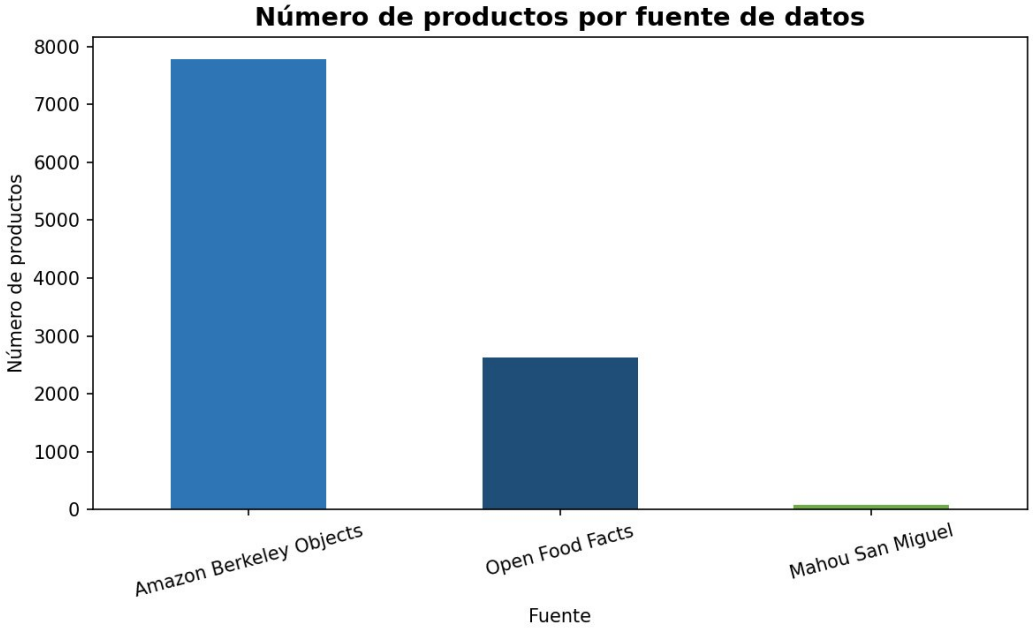

Figura 1. Número de productos por fuente de datos. Amazon Berkeley Objects aporta el 74,2% del dataset (7.777 productos), Open Food Facts el 25,0% (2.622 productos) y Mahou San Miguel el 0,8% restante (81 productos).

5.2. Distribución por categoría de producto

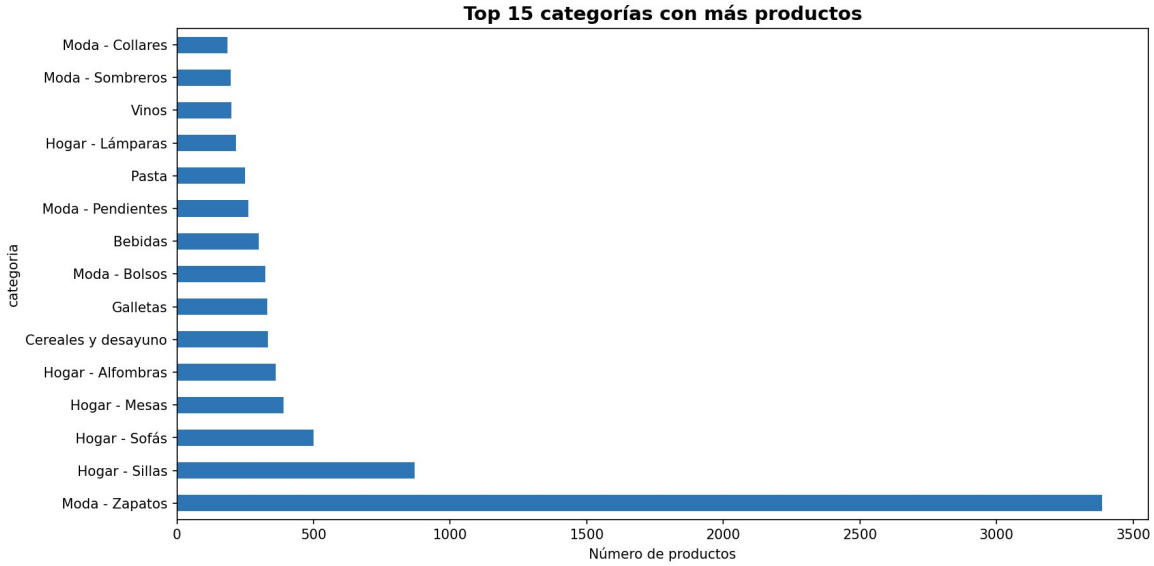

Figura 2. Top 15 categorías con mayor número de productos. La categoría Moda - Zapatos es la más representada con 3.386 productos, seguida de Hogar - Sillas (871) y Hogar - Sofás (500). El dataset cubre desde categorías de moda y hogar hasta alimentación y bebidas, proporcionando diversidad cromática entre sectores.

6. Tratamiento y limpieza del dato

6.1. Valores nulos

Se realizó una auditoría completa de valores nulos sobre todas las columnas del dataset. El resultado fue que **ninguna de las 11 columnas presenta valores nulos** (0 nulos en las 10.480 filas). Este resultado favorable se debe a que el pipeline de extracción solo incorpora al dataset productos para los que tanto la imagen como los metadatos básicos (nombre, categoría, fuente) están disponibles: si en algún paso se produce un error de descarga o la imagen no puede procesarse, el registro es descartado automáticamente sin incorporarse al CSV final.

6.2. Duplicados

Se verificó la existencia de duplicados tomando la URL de imagen como identificador único de producto. El resultado fue que **ninguna URL aparece duplicada** en el dataset. Esto confirma que el proceso de deduplicación aplicado durante la combinación de fuentes fue efectivo y que no existe sesgo por sobrerrepresentación de ningún producto concreto.

6.3. Validación de rangos teóricos

Se validó que todas las variables de color se encuentran dentro de sus rangos teóricos: RGB en [0, 255], L* en [0, 100] y a*, b* en [-128, +128]. **Las siete variables superaron la validación sin ningún valor fuera de rango**, lo que confirma la integridad del pipeline de extracción cromática.

6.4. Detección de outliers mediante el método IQR

La detección de outliers se realizó mediante el **método del rango intercuartílico (IQR)**, que define como outlier cualquier valor situado por debajo de Q1 – 1,5·IQR o por encima de Q3 + 1,5·IQR. Este método es robusto frente a distribuciones asimétricas y es el estándar más utilizado en análisis exploratorio de datos.

Variable	Outliers detectados	% sobre total	Interpretación
mean_R	7	0,07%	Imágenes con canal rojo extremo — residual
mean_G	2	0,02%	Imágenes con canal verde extremo — residual
mean_B	0	0,00%	Sin outliers — canal azul bien distribuido
mean_L	2	0,02%	Imágenes de luminosidad extrema — residual
mean_a	1.117	10,66%	Alta dispersión en el eje rojo-verde (esperado)
mean_b	749	7,15%	Alta dispersión en el eje amarillo-azul (esperado)
contrast_L	0	0,00%	Sin outliers — contraste bien distribuido

Tabla 3. Resultados de la detección de outliers por variable mediante el método IQR.

Los outliers en mean_R, mean_G, mean_B y mean_L son prácticamente residuales (menos del 0,1% en todos los casos) y corresponden a imágenes con tonos muy extremos, como packaging completamente negro o completamente blanco. No se eliminaron porque son casos reales y válidos dentro del universo de productos de consumo.

El volumen de outliers en **mean_a (10,66%)** y **mean_b (7,15%)** no es un problema sino una consecuencia esperada de la naturaleza del dataset: ambos ejes CIELAB tienen un rango teórico de [-128, +128] pero en la práctica los colores de packaging se concentran fuertemente en valores cercanos a 0 (colores neutros, blancos y grises dominantes en el e-commerce), generando una distribución leptocúrtica con colas largas que el IQR interpreta como outliers aunque sean valores completamente válidos y representativos de productos con packaging de colores saturados.

7. Análisis estadístico descriptivo

7.1. Estadísticos de las variables de color

Variable	Media	Desv. típica	Mín.	P25	Mediana	P75	Máx.
mean_R	186,07	44,32	14,79	151,04	192,18	224,04	254,51
mean_G	177,46	47,77	18,83	138,93	183,10	218,51	254,52
mean_B	170,87	52,21	23,77	128,95	176,66	215,98	254,53
mean_L	71,74	17,60	9,99	57,47	73,86	86,81	99,83
mean_a	2,95	5,88	-26,00	0,11	1,08	4,32	54,68
mean_b	5,10	8,60	-35,82	0,07	2,38	8,29	53,53
contrast_L	24,61	9,33	1,14	17,98	24,07	31,68	47,15

Tabla 4. Estadísticos descriptivos de las 7 variables de color (n = 10.480 productos).

Interpretación de las variables RGB: las tres medias (R=186,1, G=177,5, B=170,9) están claramente por encima del punto medio del rango (127,5), lo que indica que el dataset está dominado por productos con packaging de **tonos claros**. Este resultado es coherente con la composición del dataset: las imágenes de catálogo de e-commerce suelen tener fondo blanco, y categorías como moda y hogar presentan colores pastel y neutros de manera predominante.

Interpretación de L* (luminosidad CIELAB): la media de L* = 71,7 sobre un rango [0, 100] confirma la dominancia de tonos claros. La distribución es ligeramente sesgada hacia valores altos, con el 75% de los productos por encima de L* = 57,5.

Interpretación de a* y b* (cromaticidad CIELAB): ambas variables presentan medias muy próximas a 0 (a*=2,95, b*=5,10) y distribuciones fuertemente concentradas, como se aprecia en los histogramas. Esto indica que la mayoría del packaging del dataset es cromáticamente neutro (blancos, grises, beiges), con una leve tendencia hacia los tonos cálidos (a* y b* ligeramente positivos). Los valores extremos corresponden a productos con packaging altamente saturado.

Interpretación del contraste (contrast_L): la media de 24,6 con una desviación típica de 9,3 indica que el contraste interno de las imágenes es moderado y bien distribuido. Los productos con packaging más complejo visualmente (combinaciones de colores vivos con zonas blancas, por ejemplo) alcanzan valores de contrast_L superiores a 35.

7.2. Distribución de las variables de color

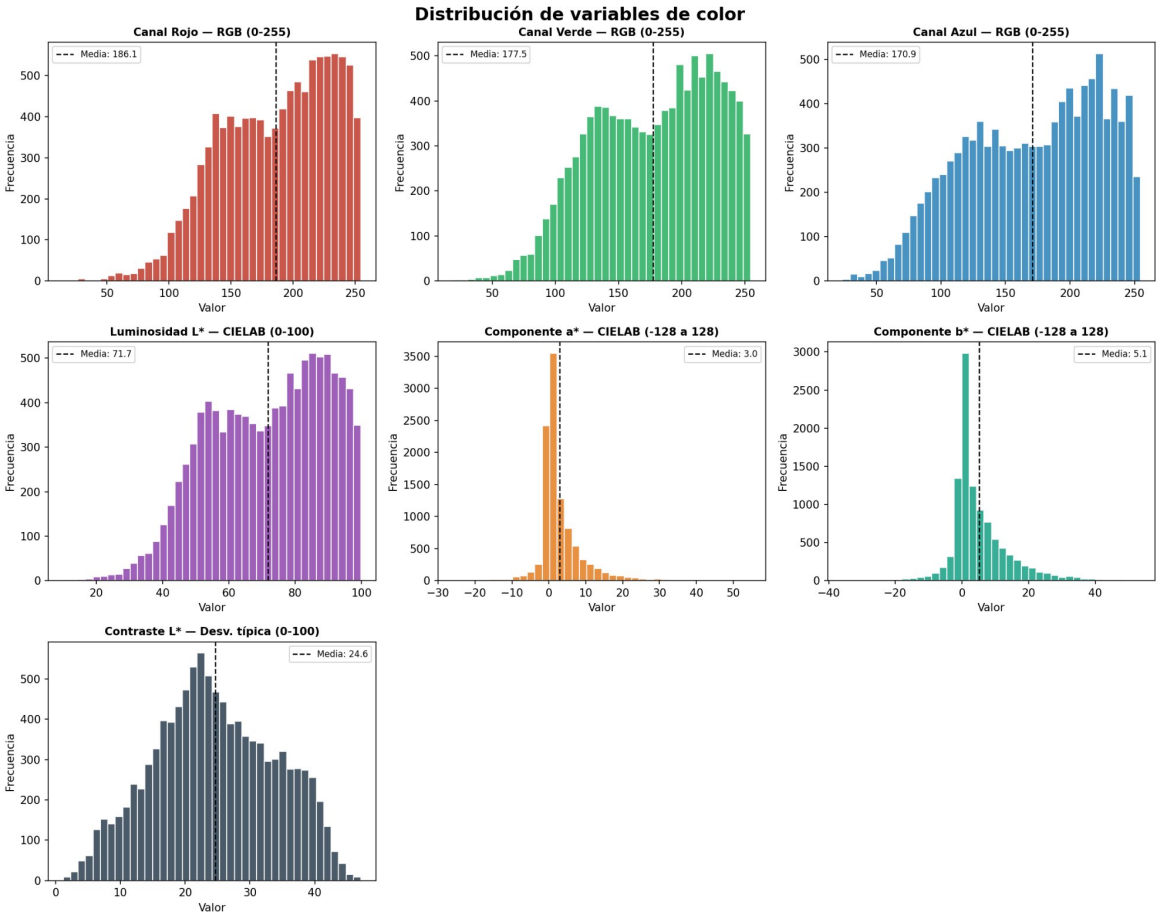

Figura 3. Histogramas de distribución de las 7 variables de color. Las variables RGB y L muestran distribuciones sesgadas hacia valores altos (tonos claros). Las variables a* y b* presentan distribuciones leptocúrticas centradas en 0 con colas largas.*

8. Análisis de correlaciones

Se calculó la **matriz de correlación de Pearson** entre las siete variables de color para identificar relaciones lineales entre ellas. Los resultados tienen implicaciones directas para el diseño del modelo predictivo posterior.

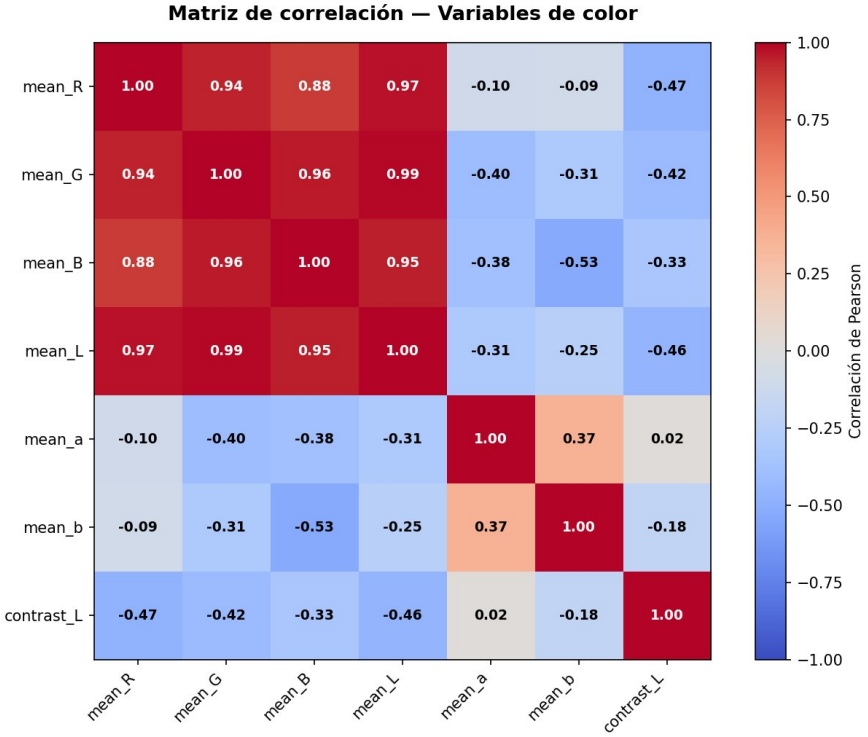

Figura 4. Matriz de correlación de Pearson entre las 7 variables de color.

8.1. Bloque RGB — L*: alta correlación interna (r > 0,88)

Las cuatro variables mean_R, mean_G, mean_B y mean_L presentan correlaciones positivas muy fuertes entre sí, con coeficientes que oscilan entre r = 0,88 (R-B) y r = 0,99 (G-L*). Esta alta correlación es matemáticamente esperable: L* en CIELAB es precisamente una transformación no lineal de los valores RGB ponderados por la sensibilidad del ojo humano a cada longitud de onda, por lo que cuando los tres canales RGB son altos (imagen clara), L* también es alto. La correlación más alta es G-L* (r=0,99) porque el ojo humano es más sensible al canal verde, que tiene el mayor peso en el cálculo de L*.

Esta correlación implica que en el modelo predictivo final probablemente no será necesario incluir simultáneamente las tres variables RGB y L*, ya que aportan información muy similar. El espacio CIELAB (L*, a*, b*) es la representación más eficiente para el análisis psicológico del color al ser perceptualmente uniforme.

8.2. Variables de cromaticidad: independencia relativa

Las variables mean_a y mean_b presentan correlaciones bajas o moderadas con el resto: la correlación entre a* y b* es r = 0,37 (moderada positiva), lo que indica que los productos con packaging más rojizo tienden también a ser ligeramente más cálidos, pero ambas variables capturan información cromática parcialmente independiente. Ambas variables muestran correlaciones negativas moderadas

con G y B (r entre -0,31 y -0,53), lo que refleja que los productos más saturados en tonos cálidos tienden a tener menores niveles de canal verde y azul.

8.3. Contraste: patrón de correlación diferenciado

La variable contrast_L presenta correlaciones negativas moderadas con las variables de luminosidad (r = -0,46 con L*, -0,47 con R), lo que indica que los productos con mayor contraste interno tienden a ser más oscuros en promedio. Esto tiene una interpretación intuitiva clara: las imágenes de fondo blanco uniforme (L* alto, contrast_L bajo) son muy frecuentes en el e-commerce, mientras que los productos con packaging oscuro y complejo (L* bajo, contrast_L alto) son menos frecuentes pero más heterogéneos. Notablemente, contrast_L muestra correlación casi nula con mean_a (r = 0,02), lo que confirma su independencia respecto a la dimensión rojo-verde.

9. Conclusiones de la ingeniería del dato

■ Dataset limpio y sin incidencias

El proceso completo de extracción, combinación y limpieza ha producido un dataset de 10.480 productos con 0 valores nulos, 0 duplicados y 7 variables de color dentro de sus rangos teóricos. El dataset está listo para la fase de modelado.

■ Representatividad y diversidad cromática

La combinación de tres fuentes con perfiles distintos (productos de moda y hogar en ABO, productos alimentarios en Open Food Facts, y cervezas y bebidas en Mahou San Miguel) proporciona una amplia diversidad cromática que enriquece el análisis. Las 67 categorías cubren desde productos neutros (blancos y beiges dominantes en moda) hasta altamente saturados (packaging de alimentación y cerveza).

■ Dominancia de tonos claros

El análisis descriptivo revela que el dataset está dominado por productos con packaging claro (media L* = 71,7 sobre 100) y cromáticamente neutro (medias a* ≈ 3, b* ≈ 5 sobre rangos de 256 puntos). Esto es un resultado del propio mercado de consumo y no un sesgo de muestreo, y debe tenerse en cuenta al interpretar los resultados del modelo.

■ Alta correlación RGB-L* con implicaciones para el modelado

Las correlaciones muy fuertes entre los canales RGB y L* sugieren que el espacio CIELAB (L*, a*, b*) es la representación más eficiente para el modelo: aporta la misma información que RGB pero en un espacio perceptualmente uniforme, directamente alineado con el marco teórico de los estudios de color-emoción citados.

■ Outliers en cromaticidad: naturaleza y tratamiento

El volumen de outliers estadísticos en mean_a y mean_b (10,7% y 7,2% respectivamente) no representa un problema de calidad sino una característica distribucional del dato. Se ha optado por no eliminarlos porque corresponden a productos con packaging genuinamente saturado que son relevantes para el análisis de color-emoción.

Referencias

- Collins, J., Goel, S. et al. (2022). ABO: Dataset and Benchmarks for Real-World 3D Object Understanding. *CVPR 2022*. https://amazon-berkeley-objects.s3.amazonaws.com/index.html
- Gilbert, A.N., Fridlund, A.J., & Lucchina, L.A. (2016). The color of emotion: A metric for implicit color associations. *Food Quality and Preference*, 52, 203-210.
- Open Food Facts contributors (2024). Open Food Facts database. Open Database License (ODbL). https://world.openfoodfacts.org
- Valdez, P., & Mehrabian, A. (1994). Effects of color on emotions. *Journal of Experimental Psychology: General*, 123(4), 394-409.